




Redes Neuronais para Previsão de Preços de Ações

Pedro Leite
M:CC @ FCUP
14 de Novembro de 2025

Conteúdos

1-2. Introdução & Teoria

3. Revisão de Artigos

4. Metodologia

5. Resultados

6. Conclusão





1-2. Introdução & Teoria

Mercado de Ações



Importância

- Permite às empresas obter capital a longo prazo, visibilidade e diversificação.
- Garante uma alocação eficiente de capital através da descoberta de preços transparente.
- Permite que indivíduos participem no crescimento económico, contribuindo para a criação de riqueza.



Desafios

- Bolhas especulativas, riscos sistêmicos e crises de liquidez ameaçam a estabilidade do mercado.
- Segundo a Efficient Market Hypothesis (EMH), os preços refletem rapidamente toda a informação disponível.
- Os dados contêm: dependência temporal, não estacionaridade e ruído elevado.

Justificação



Contexto

- Métodos tradicionais tornam-se limitados perante a complexidade dos mercados atuais.
- Métodos estatísticos assumem linearidade, estacionaridade e usam apenas uma variável.
- Métodos tradicionais de Machine Learning (ML) têm dificuldades com dependências temporais e overfitting.



Motivação

- Redes Neurais especialmente modelos sequenciais (LSTM, GRU, ...) demonstram capacidade de captar relações não lineares e dependências temporais efetivamente.
- Falta de estudos sistemáticos que comparem e otimizem metodologias e que estudem a aplicabilidade prática.



3. Revisão de Artigos

Pesquisas

Metodologia

AI, ML, DL, MLP, ANN, RNN,
CNN, LSTM, GRU, GAN, TFT

Domínio

Stock

Tarefa

Prediction, Forecasting

((“Metodologia” OR “Abreviação”) AND (“Domínio”) AND (“Tarefa 1” OR “Tarefa 2”))

Título

Acesso aberto

Inglês

Desde 1 de Janeiro de 2022 até 3 de Março de 2025

Scopus

ArXiv

IEEE Xplore

Filtração




Crítérios

- Repetidos (13%)
- Revisões sistemáticas (3%)
- Falta de foco em RNs (19%)
- Foco em modelos híbridos (40%)
- Foco em modelos alternativos (8%)
- Foco em PLN (5%)
- Diferente objetivo primário (4%)
- Mal explicado (3%)
- Outra razão (1%)



Fases

- Título (66%)
- Abstrato (21%)
- Texto (9%)



Análise



Dados e PreProcessamento

- Ações: Apple e Tesla.
- Número de Ações: 1.
- Tamanho de Dados Históricos: 11.5 anos.
- Número de variáveis: 11.
- Variáveis de Mercado: 100%.
- Indicadores Técnicos: 25%.
- PreProcessamento: Normalização (MinMax) e divisão treino-teste (80-20).



Modelos e Resultados

- Modelos: LSTM e GRU.
- Número de Camadas: Múltiplas camadas, sendo duas o número de camadas mais frequente.
- Dropout: 50%.
- Funções: ReLU, Adam e MSE.
- Previsão: "Close" para o próximo dia.
- Métricas: RMSE e MSE.

Direção da Investigação




Lacunas na Literatura

- LSTM vs GRU.
- Univariado vs Multivariado.
- Indicadores técnicos.
- Métodos de pré-processamento, hiperparâmetros e técnicas de regularização.
- Comparação entre setores ou tipos de ações.



Próximos Passos

- Optimizar e avaliar: variáveis, modelos, arquiteturas, métodos de pré-processamento, hiperparâmetros e técnicas de regularização.
- Avaliar o modelo otimizado num conjunto alargado de ações, estudando as características e setores das ações com melhores resultados.



4. Metodologia

Construção do Dataset

Ações

Ações do SP500 de 2020

Categorias de Variáveis

1 variável

5 variáveis de mercado

19 indicadores técnicos

Setup

5 anos (Junho de 2020 até Junho de 2025)


Frequência diária

Prever "Close" do próximo dia


Tarefa de Regressão

RMSE

Exploração de Dados: Temporais




Decomposição Sazonal



Correlação Temporal

Exploração de Dados: Ações



PreProcessamento de Dados

Limpeza

- 50 ações foram removidas por não terem dados.
- 52 ações foram removidas por terem dados insuficientes.
- Valores dos fim de semana foram imputados com Forward Filling.
- Valores extra para computar os indicadores técnicos foram removidos.

Transformação

- Normalização MinMax $[0,1]$.

Preparação

- Partição treino-teste 80-20.
- Janela deslizante de tamanho 30.
- Sequências das janelas deslizantes foram transformadas em arrays de 3 dimensões (número de amostras, tamanho da janela, número de variáveis).

1ª Fase de Modelagem

Ação

- Apple.

Modelos & Arquiteturas

- GRU e LSTM.
- Número de Camadas: 1, 2 e 3.
- Número de Neurónios: 8, 16, ..., 128.

Hiperparâmetros

- Epochs: 50.
- Tamanho de Batch: 1.
- Learning Rate: 0.001.
- Optimizer: Adam.
- Função de Ativação: ReLU.
- Função de Perda: MSE.

90 Combinações
(2 Modelos,
15 Arquiteturas,
3 Datasets)



5 Testes



Sistema de Pontuação
(70% Média, 20% DP,
10% CV)

2ª Fase de Modelagem

PreProcessamento

- Técnicas para lidar com Outliers: Winsorization e Clipping.
- Técnicas de Smoothing: Simple Moving Average, Rolling Median, Gaussian Filter e Salvitzky-Golay Filter.
- Fórmulas de Normalização: MinMax, Z-Score e Log-Norm.
- Tamanhos de Janela: 1, 2, 3, 4, 5, 6, 7, 15, 30, 60 e 90.

Hiperparâmetros

- Tamanho de Batch: 1, 2, 4, 8, 16, 32, 64 e 128.
- Learning Rates: 0.0001, 0.001, 0.005, 0.01 e 0.05.
- Optimizers: SGD, AdaGrad, AdaDelta, RMSprop e Adam.
- Funções de Ativação: TanH, Sigmoid, ReLU e Leaky ReLU.
- Funções de Perda: MSE, RMSE, MAE e MAPE.

Regularização

- Dropout.
- Early Stopping.
- L2 Regularization.
- Batch Normalization.
- Recurrent Dropout.
- Gradient Clipping.
- Data Augmentation.

3ª Fase de Modelagem

Estratégia

- Modelo final otimizado.
- 403 ações.

Métricas

- Regressão: RMSE, MSE, MAE, MAPE e R^2 .
- Classificação: Accuracy, Precision, Recall e F1.

Análises

- Análise estatística de performance.
- Correlação entre performance e métricas.
- Segmentação da Performance: Bom, Medíocre e Mau.
- Análise de Risco-Retorno que mede a variação entre os preços previstos e a sua volatilidade.



5. Resultados

1ª Fase de Modelagem

Variáveis


Dataset univariado e de mercado demonstraram resultados competitivos, enquanto o dataset técnico deteriorou significativamente os resultados.

Modelos

GRU demonstrou no geral melhores resultados, mas LSTM funcionou melhor no dataset univariado.

Arquiteturas

Arquiteturas menos profundas consistentemente demonstraram melhor resultados, nos três datasets e nos dois modelos.



2ª Fase de Modelagem

PreProcessamento

- Técnicas para Lidar com Outliers: Nenhum.
- Técnica de Smoothing: Nenhum.
- Fórmula de Normalização: MinMax.
- Tamanho de Janela: 30.

Hiperparâmetros

- Tamanho de Batch: 1.
- Learning Rate: 0.001.
- Optimizer: Adam.
- Função de Ativação: ReLU.
- Função de Perda: MAPE.

Regularização

- Nenhum.

3ª Fase de Modelagem

MAPE: 10.8%
R²: -4.25



Acc: 51.1%
Prec: 66.9%



11.7% apresentam
“bons” resultados



Destaque do
setor financeiro






6. Conclusão

Resumo

- Modelo ideal é um GRU 3x8 com variáveis de mercado, Adam ($\text{lr}=0.001$), batch único, ReLU e MAPE.
- Datasets mais simples (univariado e de mercado) apresentaram os melhores resultados.
- GRU demonstrou melhores resultados no geral.
- Arquiteturas rasas superaram redes mais profundas.
- 11.7% das ações apresentaram “bom” desempenho.
- Modelo demonstrou preferência por preços baixos, volatilidade reduzida, métricas risk-adjusted superiores e pelo setor financeiro.

Trabalho Futuro

- Incluir décadas de dados para avaliar arquiteturas mais profundas e complexas.
- Explorar estratégias adaptativas que ajustem a complexidade do modelo com base em características individuais de cada ação.
- Incluir outro tipo de variáveis como indicadores de sentimento e técnicas de feature selection e redução de dimensionalidade.
- Aumentar o número de execuções de otimização para maior confiabilidade dos resultados.
- Usar o modelo GRU otimizado como baseline para modelos híbridos e alternativos.



Obrigado!

*“Redes Neurais para
Previsão de Preço de Ações”*

Trabalho realizado por Pedro Leite
M:CC @ FCUP 2024/2025